

Nichtparametrische Statistik

Kap1 Gauss - Test

$$H_0: M = M_0$$

Behauptung: $Z = \frac{\sqrt{n}(\bar{X} - M_0)}{\sigma} \stackrel{H_0}{\sim} N(0,1)$

Ann: X_1, \dots, X_n unabhängig und identisch
verteilt wie $X \sim N(M, \sigma^2)$

[Geg: $n=9$ und $\sigma^2 = 0.18^2$ und $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$]

Bew: ① Normalverteilung von Z folgt direkt aus
der Verteilungsannahme für X
(X ist normalverteilt $\Rightarrow \bar{X}$ ist normalverteilt $\Rightarrow Z$ ist normalv.)
 $\sim N(\mu, \sigma^2)$ $\sim N(M, \frac{\sigma^2}{n})$ $\stackrel{?}{\sim} N(0,1)$

② $E\left[\frac{\sqrt{n}(\bar{X} - M_0)}{\sigma}\right] = \frac{\sqrt{n}}{\sigma} E\left[\left(\frac{1}{n} \sum_{i=1}^n X_i\right) - M_0\right] =$
 $= \frac{\sqrt{n}}{\sigma} \left[\underbrace{\left(\frac{1}{n} \sum_{i=1}^n E(X_i)\right)}_{M} - M_0 \right] = \frac{\sqrt{n}}{\sigma} [M - M_0] = 0$
 \uparrow
"unter H_0 "
($= H_0$ wahr ($M = M_0$))

③ $V\left(\frac{\sqrt{n}(\bar{X} - M_0)}{\sigma}\right) = \frac{n}{\sigma^2} V\left(\left(\frac{1}{n} \sum_{i=1}^n X_i\right) - M_0\right) =$
 $= \frac{n}{\sigma^2} V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{\sigma^2 n} V\left(\sum_{i=1}^n X_i\right) =$

$$= \frac{1}{\sum_{i=1}^n} \left[\sum_{i=1}^n W(X_i) \right] = \frac{1}{\sum_{i=1}^n} \cdot [n \cdot \zeta^2] = 1$$

□

Unabhängigkeit
zwischen X_i und X_j
für alle $i \neq j = 1, \dots, n$

P-Wert

Zweiseitiger Test:

$$P = P_{H_0}(|T| \geq |T_{\text{beob}}|)$$

Einseitige Versionen

$$H_1: M > M_0$$

$$P_{\text{größer}} = P_{H_0}(T \geq T_{\text{beob}})$$

$$H_1: M < M_0$$

$$P_{\text{kleiner}} = P_{H_0}(T \leq T_{\text{beob}}),$$

wobei

$$P = 2 \cdot \min \{ P_{\text{kleiner}}, P_{\text{größer}} \}$$

(zweiseitig)

Die Gütefunktion

$$\beta(n, \alpha, \theta, \theta_0) = P\left(\begin{array}{l} \text{"Ablehnung von } H_0 \text{, falls wahr"} \\ \text{Parameterwert } \theta \in \Omega_0 \cup \Omega_1 \end{array}\right)$$

oft unterschlagen

. $\beta(n, \alpha, \theta) \leq \alpha$ für alle $\theta \in \Omega_0$.

Achtung!: Falls $\beta(n, \alpha, \theta) > \alpha$ für mind. ein $\theta \in \Omega_0$

=> ungültiger Test

Ideal: $\beta(n, \alpha, \theta) = \alpha$ für alle $\theta \in \Omega_0$
(oder zumindest für mind.
ein $\theta \in \Omega_0$)

- Falls $\beta(n, \alpha, \theta) < \alpha$ für all $\theta \in \Omega_0$,
nennt man den dazugehörigen Test
"konservativ".
- Für $\theta \in \Omega_1$ ist $\beta(n, \alpha, \theta)$ die Wahrscheinlichkeit
die richtige Entscheidung zu treffen (H_0 ablehnen).

Ideal: $\beta(n, \alpha, \theta) \approx 1$ für alle $\theta \in \Omega_1$

• "unvorfalschter Test"

$$\beta(n, \alpha, \theta \in \Sigma_1) \geq \beta(n, \alpha, \theta \in \Sigma_0)$$

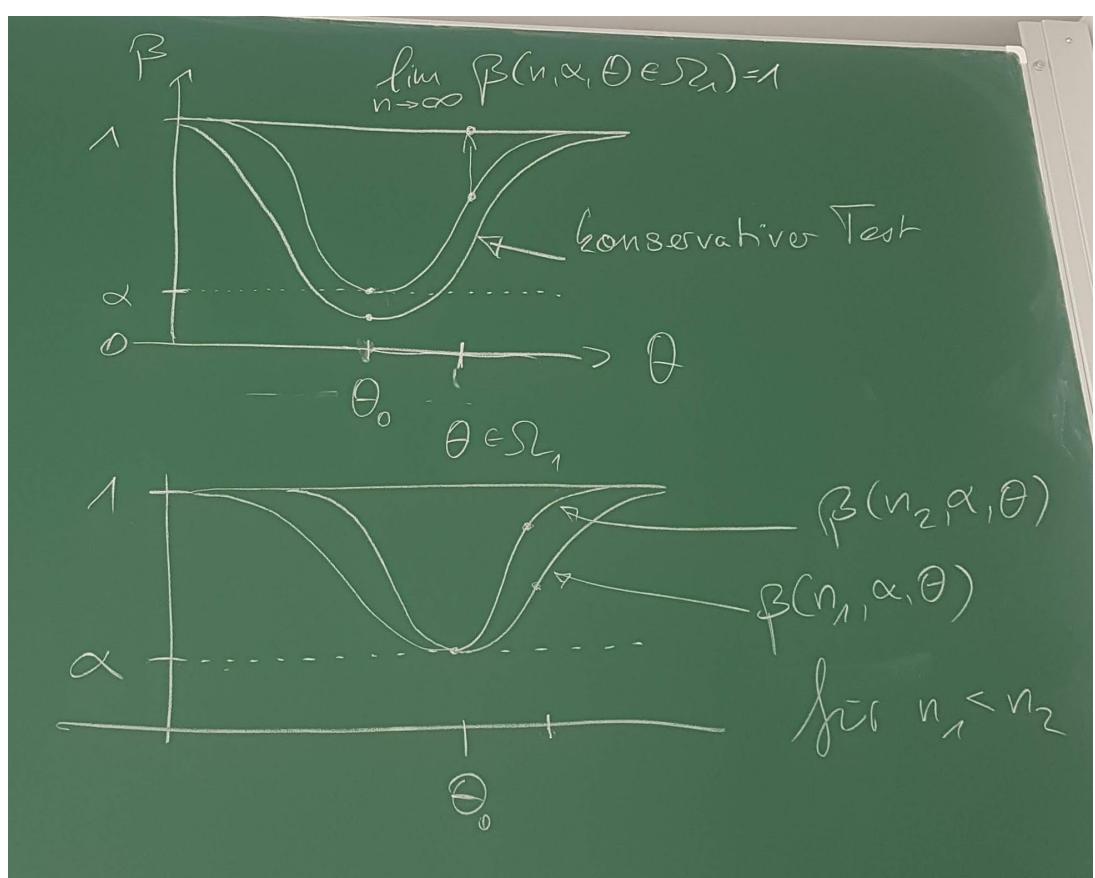
• "konsistenter Test"

$$\beta(n, \alpha, \theta) \xrightarrow{n \rightarrow \infty} 1 \text{ für alle } \theta \in \Sigma_1$$

• Seien β und β^* die Gütefunktionen von zwei unterschiedlichen Tests (t-Test und z-Test).

Falls $\beta(n, \alpha, \theta) \geq \beta^*(n, \alpha, \theta)$ für alle n und für alle $\theta \in \Sigma_1$,

dann nennt man den zu β gehörigen Test "gleichmäßig bester" Test.



Die Gütekoeffizienten des z-Tests

- $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$ für alle $i = 1, \dots, n$
- $H_0: \mu = \mu_0$ versus $H_1: \mu \neq \mu_0$

$$z = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} = \frac{\bar{X} - \mu_0}{\sqrt{\frac{\sigma^2}{n}} \text{Var}(\bar{X})} = \frac{\bar{X} - \mu + (\mu - \mu_0)}{\sqrt{\frac{\sigma^2}{n}}} \\ = \underbrace{\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}}}_{\sim N(0,1)} + \frac{\mu - \mu_0}{\sqrt{\frac{\sigma^2}{n}}} \sim N\left(\frac{\mu - \mu_0}{\sqrt{\frac{\sigma^2}{n}}}, 1\right)$$

↗
Verteilung von z unter
 H_0 und H_1

$$\beta_z(n, \alpha, \mu, \mu_0) = P(z > z_{1-\frac{\alpha}{2}}) + P(z < -z_{\frac{\alpha}{2}})$$

$(1 - \frac{\alpha}{2})$ und $(\frac{\alpha}{2})$ Quantile von $N(0,1)$

Simulation einer Gütekoeffizienten (Beispiel t-Test)

Zufallsstichprobe

$$(X_1, \dots, X_n), \text{ wobei: } X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$$

$$T = T(X_1, \dots, X_n) = \frac{\sqrt{n}(\bar{X} - \mu_0)}{s} \stackrel{H_0}{\sim} t_{n-1} \quad (z.B. 10000)$$

Per Zufallszahlengenerator erzeugen wir nun $b = 1, 2, \dots, B$

Realisationen von $(X_1^{(b)}, \dots, X_n^{(b)}) \Rightarrow T^{(b)} = \frac{\sqrt{n}(\bar{X}^{(b)} - \mu_0)}{s^{(b)}}$

$$\beta_t(n, \alpha, M, M_0) = P\left(\begin{array}{l} \text{"H}_0 \text{ ablehnen falls wahr} \\ \text{Parameterwert } M \end{array}\right)$$

$$\approx \frac{1}{B} \sum_{b=1}^B \mathbb{I}(\tau^{(b)} \in C)$$

Starke Gesetz der großen Zahlen:

$$\frac{1}{B} \sum_{b=1}^B \mathbb{I}(\tau^{(b)} \in C) \xrightarrow[B \rightarrow \infty]{\text{a.s.}} E(\mathbb{I}(\tau \in C)) = \underline{\underline{P(\tau \in C)}} \cdot 1 + \underline{\underline{P(\tau \notin C)}} \cdot 0$$

unter H_0 :

$$\underline{\underline{P(\tau \in C)}} = \mathbb{E}(\mathbb{I}(\tau \in C)) = \alpha$$

unter H_1 :

$$\overline{\mathbb{E}(\mathbb{I}(\tau \in C))} \geq \alpha$$

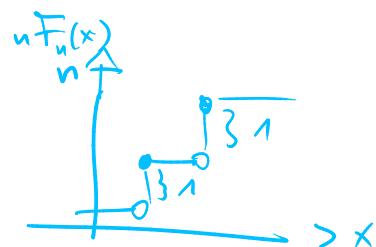
Kapitel 2

Locale Eigenschaften von $F_n(x)$

↑ d.h. für ein "festes" x

$$F_n(x) \in \left\{ 0, \frac{1}{n}, \frac{2}{n}, \dots, 1 \right\}$$

$$\Leftrightarrow n \cdot F_n(x) \in \left\{ 0, 1, \dots, n \right\}$$



Satz: Sei X_1, \dots, X_n iid wie $X \sim F$,
wobei ~~unstetig und~~ $X \in \mathbb{R}$.

Dann gilt für jedes feste $x \in \mathbb{R}$

$$P(F_n(x) = \frac{m}{n}) = \binom{n}{m} (F(x))^m (1-F(x))^{n-m}$$

$$P(n \cdot F_n(x) = m)$$

d.h. $F_n(x) \sim \text{Binom}(n, p = F(x))$

Setze $Y_i(x) = \mathbb{1}(X_i \leq x) \in \{0, 1\}$

$$P(Y_i(x) = 1) = P(X_i \leq x) = F(x)$$

$$P(Y_i(x) = 0) = P(X_i > x) = 1 - F(x)$$

Somit ist $Y_i(x) \in \{0, 1\}$ eine

Bernoulli Z.V.

$$Y_i(x) \sim \text{Bern}(p = F(x))$$

Damit:

$$n F_n(x) = \sum_{i=1}^n \mathbb{1}(X_i \leq x) \in \{0, 1, \dots, n\}$$

binomialverteilt mit Parametern n und $p=F(x)$

D.h.:

$$P(nF_n(x) = m) = \binom{n}{m} (F(x))^m (1-F(x))^{n-m}$$

$$P(F_n(x) = \frac{m}{n})$$

□

Da $n \cdot F_n(x) \sim \text{Binom}(n, p=F(x))$

$$1. \quad E(nF_n(x)) = n \cdot F(x)$$

$$\Leftrightarrow E(F_n(x)) = F(x)$$

D.h. $F_n(x)$ ist erwartungstreuer Schätzer für $F(x)$

$$2. \quad \text{Var}(nF_n(x)) = n \cdot F(x)(1-F(x))$$

$$\Leftrightarrow n^2 \text{Var}(F_n(x)) = n \cdot F(x)(1-F(x))$$

$$\Leftrightarrow \text{Var}(F_n(x)) = \frac{1}{n} F(x)(1-F(x))$$

D.h. $\text{Var}(F_n(x)) \xrightarrow{n \rightarrow \infty} 0$

3. Behauptung: $F_n(x)$ ist (schwach) konsistenter Schätzer für $F(x)$

D.h. $F_n(x) \xrightarrow{n \rightarrow \infty} P$

Tschébyseff-Ungleichung -

$$P(|X - E(X)| < b) \geq 1 - \frac{\text{Var}(X)}{b^2} \quad \text{für } b > 0$$

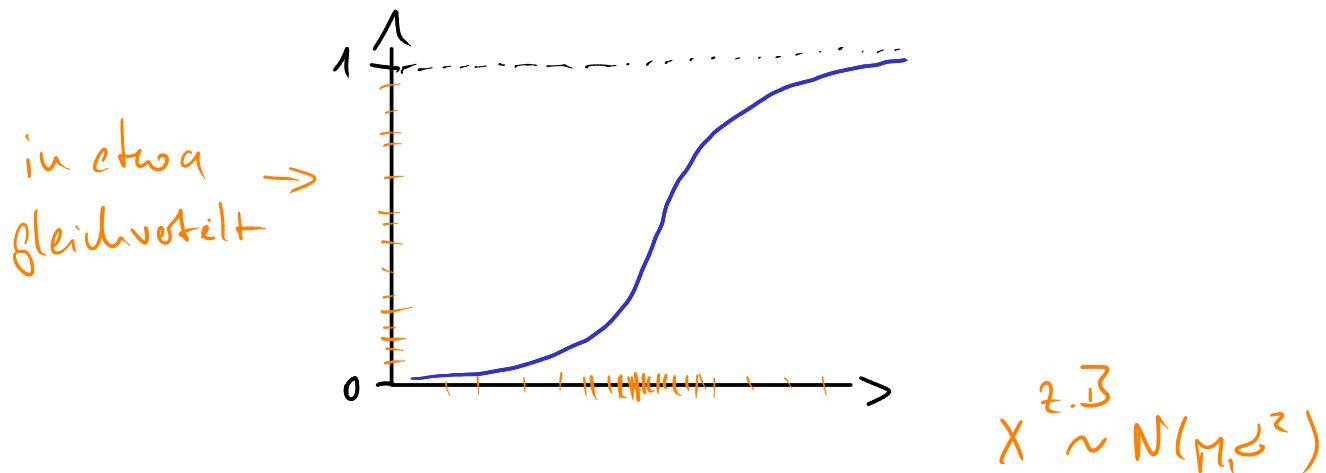
$$\left(\Leftrightarrow P(|X - E(X)| > b) \leq \frac{\text{Var}(X)}{b^2} \right)$$

Hier:

$$1 \geq P(|F_n(x) - \tilde{F}(x)| < b) \geq 1 - \frac{\frac{1}{n} F(x)(1-F(x))}{b^2}$$

$\xrightarrow{n \rightarrow \infty} 1$

Zum Satz, dass $F(X) \sim U[0,1]$, wobei
 $X \sim F$ und F stetig ist.



Randnotiz

Inverse uniform integral transform

$$X = F^{-1}(U) \quad U \sim U[0,1]$$

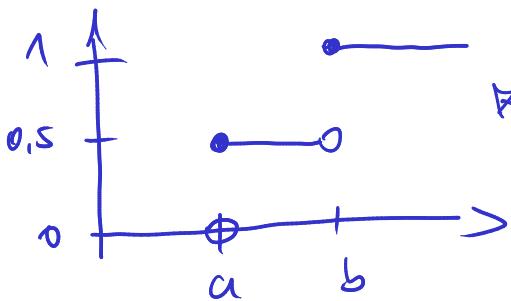
$$\Rightarrow X \sim F$$

Nicht-Robustheit des Mittelwerts

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \longrightarrow \infty \quad \text{für } x_1 \rightarrow \infty$$

und alle anderen
 (x_2, \dots, x_n) fest.

Quantile



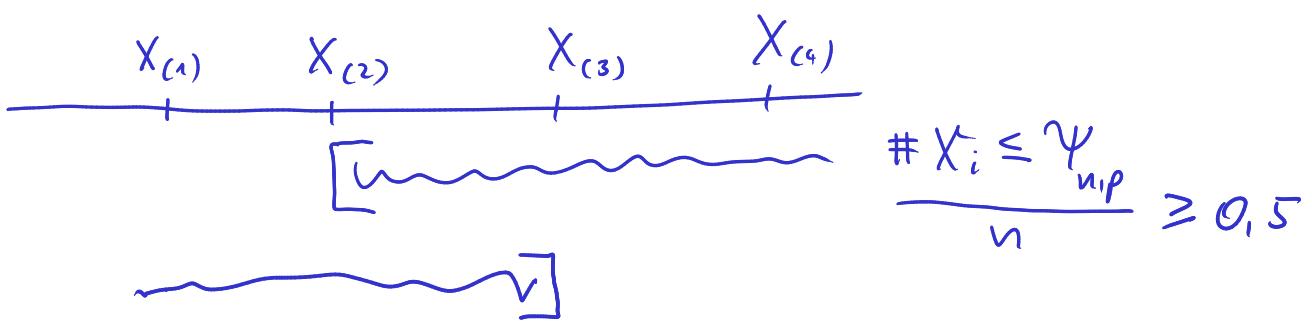
Verteilungsfunktion von X

$$p = 0,5$$

$$P(X < \Psi_{0,5}) \leq 0,5 \leq P(X \leq \Psi_{0,5})$$

gilt für alle $\Psi_{0,5} \in [a, b]$

Empirisches Quantil (Bsp. $p = 0,5$ und $n = 4$)



$$\Rightarrow \Psi_{n,p} = \Psi_{4,0,5} \in [X_{(2)}, X_{(3)}]$$

$\Psi_{n,p}$ "approximiert" Ψ_p

$\Psi_{n,p}$ ist ein konsistenter "Punktschätzer" für Ψ_p .

Unter gewissen Voraussetzungen (siehe B&T, Kap 3.4.8)

gilt, dass $\Psi_{n,p} \xrightarrow{P} \Psi_p$ für $n \rightarrow \infty$

Konfidenzintervall für Quantile

Ziel: Finde $X_{(k)}$ und $X_{(e)}$, wobei $k < e$, sodass

$$\begin{aligned} P(X_{(k)} < \psi_p < X_{(e)}) &= \\ = P(\psi_p \in \underbrace{[X_{(k)}, X_{(e)}]}_{}) &\geq 1-\alpha \end{aligned}$$

$$F(X_{(k)}) \sim U[0,1]$$

$$F(X) \sim U[0,1]$$

$(1-\alpha) \cdot 100\%$ Konfidenz-
intervall für ψ_p .

Ann: Die Verteilungsfunktion F von X sei
stetig und streng monoton wachsend.

Da F streng monoton wachsend ist,
gilt folgende Identität von Zufallsereignissen:

$$X_{(k)} < \psi_p \iff F(X_{(k)}) < \underbrace{F(\psi_p)}_{=p}$$

$$X_{(e)} > \psi_p \iff F(X_{(e)}) > \underbrace{F(\psi_p)}_{=p}$$

Somit: $P(X_{(k)} < \psi_p < X_{(e)}) =$

$$= P(F(X_{(k)}) < p < F(X_{(e)}))$$

Mögliche Zufallsrealisationen

1. $X_{(k)} < \psi_p < X_{(k+1)} \Leftrightarrow \sum_{i=1}^n \mathbb{I}(F(X_{(i)}) < p) = k \sim U[0,1]$
2. $X_{(k+1)} < \psi_p < X_{(k+2)} \Leftrightarrow \sum_{i=1}^n \mathbb{I}(F(X_{(i)}) < p) = k+1$
- \vdots
- ($k-1$) $X_{(k-1)} < \psi_p < X_{(k)} \Leftrightarrow \sum_{i=1}^n \mathbb{I}(F(X_{(i)}) < p) = k-1 \sim \text{Binom}(n, p)$

Also: $P(X_{(k)} < \psi_p < X_{(e)}) =$

$$= \sum_{j=k}^{l-1} \binom{n}{j} p^j (1-p)^{n-j} \geq 1-\alpha$$

↗

Ziel: suche k und l ,
Sodass diese Ungleichung erfüllt ist.

KS-Test

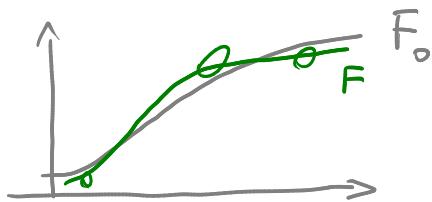
Annahme A: $X_1, \dots, X_n \stackrel{iid}{\sim} F$, wobei F stetig und
streng monoton
wachsend
(d.h. $F(x_1) < F(x_2)$,
für alle $x_1 < x_2$)

Zweiseitiger Test:

- $H_0: F = F_0$ ($H_0: F(x) = F_0(x)$ für alle $x \in \mathbb{R}$)
 $H_1: F(x) \neq F_0(x)$ für mind. ein $x \in \mathbb{R}$

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x)|$$

H_1 -Szenario:



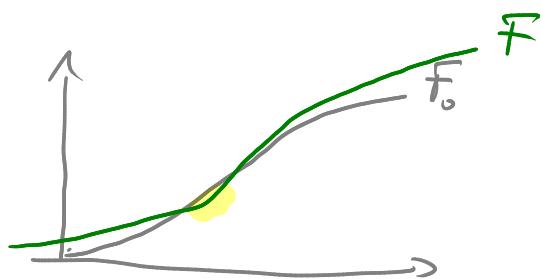
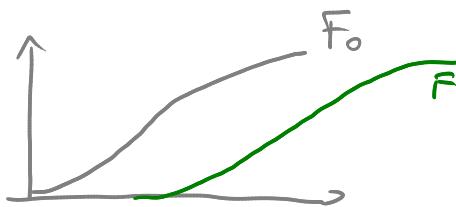
einsseitig

$$D_n^- = \sup_{x \in \mathbb{R}} (F_0(x) - F_n(x))$$

$H_0: F(x) \geq F_0(x)$ für alle $x \in \mathbb{R}$

$H_1: F(x) < F_0(x)$ für mind. ein $x \in \mathbb{R}$

H_1 -Szenarien:



$$D_n^+ = \sup_{x \in \mathbb{R}} (F_n(x) - F_0(x))$$

$H_0: F(x) \leq F_0(x)$ für alle $x \in \mathbb{R}$

$H_1: F(x) > F_0(x)$ für mind. ein $x \in \mathbb{R}$.

Beachte: $D_n = \max \{ D_n^+, D_n^- \}$

Berechnung von D_n^+ , D_n^- und D_n

Unter der Annahme A (F stetig und str. monoton wachsend)

gilt, dass $F_n(x) = \frac{i}{n}$ für alle $x \in [x_{(i)}, x_{(i+1)}]$

(D.h. nur solche F_0 , die Annahme A)
erfüllen, machen Sinn!

Sei $x_{(0)} = -\infty$ und $x_{(n+1)} = \infty$

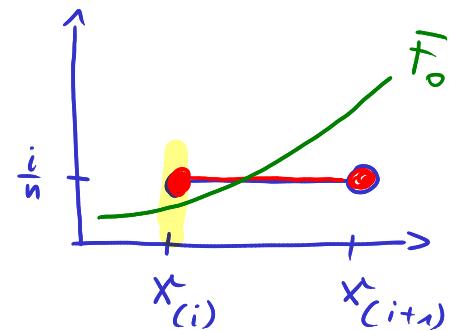
$$D_n^+ = \sup_{x \in \mathbb{R}} (F_n(x) - F_0(x))$$

$$= \max_{0 \leq i \leq n} \left(\sup_{x_{(i)} \leq x < x_{(i+1)}} (F_n(x) - F_0(x)) \right)$$

da F_0 (erfüllt Annahme A) streng
monoton wachsend und F_n konstant \Rightarrow

$$= \max_{0 \leq i \leq n} (\bar{F}_n(x_{(i)}) - F_0(x_{(i)}))$$

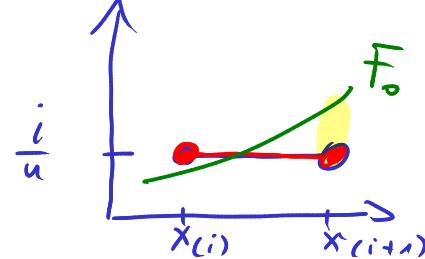
$$= \max_{0 \leq i \leq n} \left(\frac{i}{n} - F_0(x_{(i)}) \right)$$



$$D_n^- = \sup_{x \in \mathbb{R}} (F_0(x) - F_n(x))$$

$$= \max_{0 \leq i \leq n} \left(\sup_{x_{(i)} \leq x < x_{(i+1)}} (F_0(x) - \bar{F}_n(x)) \right)$$

$$= \max_{0 \leq i \leq n} \left(\bar{F}_0(x_{(i+1)}) - \bar{F}_n(x_{(i)}) \right)$$



$$= \max_{0 \leq i \leq n} \left(F_0(x_{(i+1)}) - \frac{i}{n} \right)$$

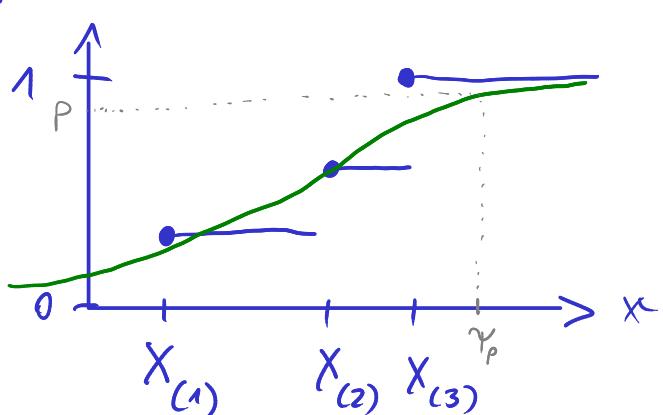
Für $D_n = \max \{ D_n^+, D_n^- \}$

Verteilungsfreiheit von D_n

unter $H_0: F_0 = F$

(und im Folgenden unter der Annahme A)

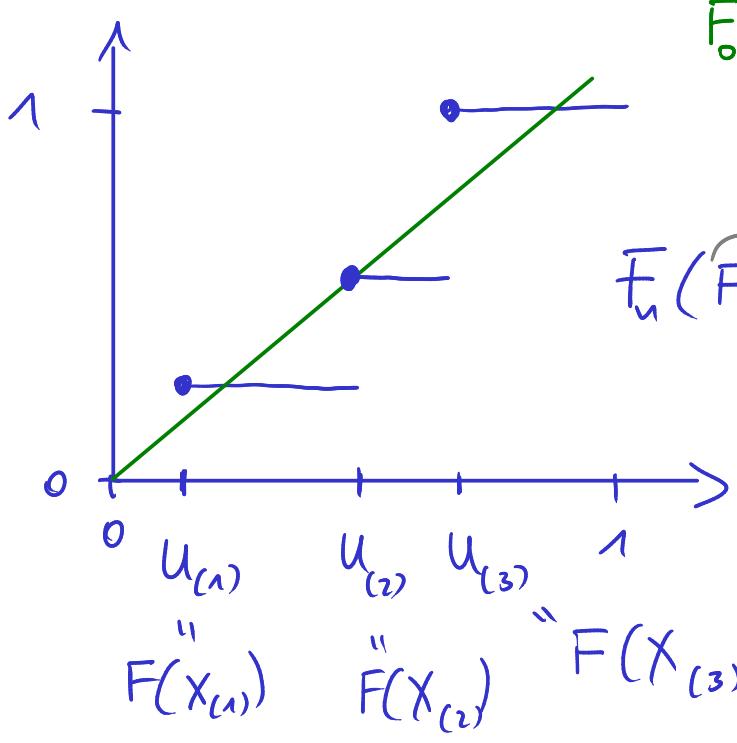
Motivation:



$$\begin{aligned} F_n(x) &= F_n(\tilde{F}^{-1}(p)) \\ F(x) &\stackrel{H_0}{=} F_0(x) = \tilde{F}_0(\tilde{F}^{-1}(p)) \\ &= p_x \end{aligned}$$

unter H_0
Identitätsfunktion

- Für jedes $x \in \mathbb{R}$ existiert genau ein $p \in [0, 1]$, sodass $\gamma_p = x$, wobei γ_p das p -Quantil der Verteilung F ist.
- $\gamma_p = x \iff \tilde{F}^{-1}(p) = x \stackrel{H_0}{\iff} \tilde{F}_0^{-1}(p) = x$
- $F(X_{(i)}) = U_{(i)}$ mit $U \sim U[0, 1]$
 $\stackrel{H_0}{\iff} F_0(X_{(i)}) = U_{(i)}$



$$F(\tilde{F}(p)) = \tilde{F}_o(p) \stackrel{H_0}{=} I(p) = p$$

"Identitätsfunktion"

$$\tilde{F}_n(\tilde{F}(p)) = \tilde{F}_n(p)$$

Unter $H_0: F_o = F$ ist
 \tilde{F}_n die empirische
Verteilungsfunktion
basierend

$$(F(X_1), \dots, F(X_n)),$$

wobei $F(X_i) \stackrel{iid}{\sim} U[0,1]$

Herleitung der Verteilungsfreiheit von
 D_n unter $H_0: F_o = F$ (und unter Annahme A)

$$\begin{aligned} D_n &= \sup_{x \in \mathbb{R}} |F_o(x) - F_n(x)| \\ &= \sup_{p \in [0,1]} |F_o(\gamma_p) - F_n(\tilde{\gamma}_p)| \end{aligned}$$

"s.t."
 \downarrow

- Für jedes $x \in \mathbb{R}$ existiert genau ein $p \in [0,1]$, sodass $\gamma_p = x$.
 $[\forall x \in \mathbb{R}, \exists! p \in [0,1] \text{ s.t. } \gamma_p = x]$
 "für alle"

- unter $H_0: F_0 = F$ gilt:

$$F_0(\Psi_p) = F_0(F^{-1}(p)) \stackrel{H_0}{=} F(F^{-1}(p)) = p$$

$$F^{-1}(p) \stackrel{H_0}{=} F_0^{-1}(p)$$

$$\Rightarrow D_n \stackrel{H_0}{=} \sup_{p \in [0,1]} |p - \underbrace{F_n(F_0^{-1}(p))}_{\tilde{F}_n(p)}|$$

↗

Empirische VF basierend auf
 $(F_0(x_1), \dots, F_0(x_n))$

wobei unter $H_0: F_0 = F$ gilt

$$F(x_i) \stackrel{iid}{\sim} U[0,1] \text{ für alle } i=1, \dots, n.$$

Motivation warum Testentscheidungen basierend

auf $D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x, \hat{\theta})|$ ($\hat{\theta} \approx \theta_{\text{wahr}}$)

und den kritischen Werten von

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x, \theta_{\text{wahr}})|,$$

wobei die Stochastik von $\hat{\theta}$ ignoriert wird, konservativ sind.

Grund:

$$\sup_{x \in \mathbb{R}} |F_n(x) - F_0(x, \hat{\theta})| \leq \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x, \theta_{\text{wahr}})|$$

χ^2 -Anpassungstest

Beispiel:

$$q=2$$

$$n=6 (=u_1+u_2)$$

$u_1 = 2$
$u_2 = 4$

$$H_0: \pi_1 = \pi_1^0 = 0,5$$

und

$$\pi_2 = \pi_2^0 = 0,5$$

$$(\pi_1^0 + \dots + \pi_q^0 = 1)$$

$$H_1: "H_0 \text{ falsch}"$$

beobachtete Zufallsrealisation

$$Q_{\text{beob}} = \sum_{j=1}^2 \frac{(u_j - n \cdot \bar{\pi}_j^0)^2}{n \cdot \bar{\pi}_j^0} = \frac{(2-3)^2}{3} + \frac{(4-3)^2}{3} = \frac{2}{3}$$

Bestechnung des p-Wertes

$$\begin{aligned} \text{p-Wert} &= P_{H_0}(Q \geq Q_{\text{beob}}) \\ &= 1 - P_{H_0}(Q < \underline{Q_{\text{beob}}}) \\ &= 1 - 0,3125 = 0,6875 \end{aligned}$$

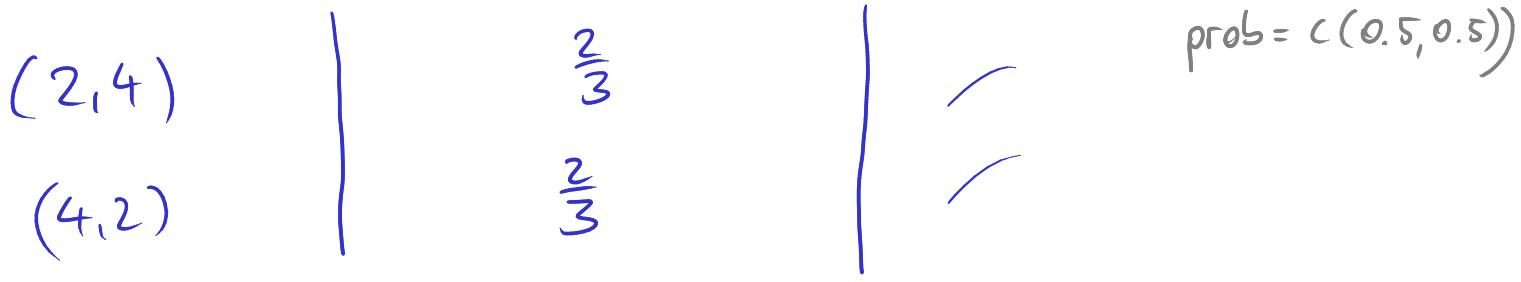
Q ist diskrete Zufallsvariable, da u_1 und u_2 nur diskrete Werte annehmen.

$$P_{H_0}(Q < \frac{2}{3}) = \sum_{\{(m_1, m_2) | Q < \frac{2}{3}\}} P(u_1=m_1, u_2=m_2) = 0,3125$$

↑
Binomialverteilung
($n, p = 0,5$)

(m_1, m_2)	Q	$P(u_1=m_1, u_2=m_2)$
$(3,3)$	$\frac{(3-3)^2}{3} + \frac{(3-3)^2}{3} = 0$	$0,3125$

dmultinom($x=c(3,3)$,
size=6,



Dammerregel zur Diskretisierung von stetigen Verteilungen (Folie 37)

$$\frac{n}{10} \leq q \leq \frac{n}{5},$$

und die A_j -Klassen so dass ungefähr gleich viele Datenpunkte pro Klasse vorhanden sind.

Verteilung der Ränge

Sei X_1, \dots, X_n iid wie $X \sim F$ mit F stetig.

Rang von X_i

$$r(X_i) = \sum_{j=1}^n \mathbb{I}(\underbrace{X_i - X_j}_{x_i \geq x_j} \geq 0)$$

Anzahl der Stichprobenvariablen, die X_i nicht übertreffen.

- $r(X_i) \in \{1, 2, \dots, n\}$

$$P(\Gamma(X_i) = a) = \frac{1}{n} \quad \text{für alle } a = 1, 2, \dots, n$$

- $(\Gamma(X_1), \dots, \Gamma(X_n)) \in A = \left\{ (a_1, \dots, a_n) \in \underbrace{\{1, \dots, n\}^n}_{\substack{a_1=1,2,\dots,n \\ a_2=1,2,\dots,n}} \mid a_i \neq a_j, 1 \leq i, j \leq n, i \neq j \right\}$
- $\begin{matrix} 1, 2, \dots, n \\ 3, 1, \dots, 5 \\ 2, 7, \dots, 3 \end{matrix}$
 $\begin{matrix} \{1, \dots, n\} \times \{1, \dots, n\} \times \dots \times \{1, \dots, n\} \\ a_1 \quad a_2 \quad \dots \quad a_n \end{matrix}$

$$\begin{aligned} P((\Gamma(X_1), \dots, \Gamma(X_n)) = (a_1, \dots, a_n)) &= \frac{1}{n} \cdot \frac{1}{n-1} \cdot \frac{1}{n-2} \cdot \dots \cdot \frac{1}{1} \\ &= \frac{1}{n!} \end{aligned}$$

für alle $(a_1, \dots, a_n) \in A$

$$\begin{aligned} \mathbb{E}(\Gamma(X_i)) &= \sum_{j=1}^n j \underbrace{P(\Gamma(X_i) = j)}_{\frac{1}{n}} = \frac{1}{n} \sum_{j=1}^n j = \frac{1}{n} \frac{n(n+1)}{2} \\ \Rightarrow \mathbb{E}(\Gamma(X_i)) &= \frac{(n+1)}{2} \end{aligned}$$

$$\text{BSP } n=5, \mathbb{E}(\Gamma(X_i)) = 3, \quad 1 \ 2 \ 3 \ 4 \ 5$$

$$\mathbb{V}\sigma(\Gamma(X_i)) = E(\Gamma(X_i)^2) - (\mathbb{E}(\Gamma(X_i)))^2$$

$$\begin{aligned} \mathbb{E}(\Gamma(X_i)^2) &= \sum_{j=1}^n j^2 \underbrace{P(\Gamma(X_i)^2 = j^2)}_{\substack{P(\Gamma(X_i) = j) \\ = \frac{1}{n}}} \\ &= \sum_{j=1}^n j^2 \underbrace{P(\Gamma(X_i) = j)}_{\substack{= \frac{1}{n}}} \end{aligned}$$

$$= \frac{1}{n} \sum_{j=1}^n j^2 = \frac{1}{n} \left(\frac{1}{6} n(n+1)(2n+1) \right)$$

$$\Rightarrow \text{Var}(\Gamma(X_i)) = \frac{1}{6}(n+1)(2n+1) - \left(\frac{n+1}{2}\right)^2$$

$$= \dots = \frac{n^2 - 1}{2}$$

$$\text{Cor}(\Gamma(X_i), \Gamma(X_j)) = \text{Übungsbuch 2}$$

für $i \neq j$

Lineare Rangstatistiken

Tests auf Lagealternativen

IQ Beispiel:

$$H_0: M_{\text{med}} = M_0$$

$$H_0: M_{\text{med}} = 110$$

$$H_1: M_{\text{med}} \neq M_0$$

$$H_1: M_{\text{med}} \neq 110$$

- Differenzen: $D_i = X_i - M_0$

- Ränge der absoluten Differenzen: $\Gamma(|D_i|)$

- Vorzeichen (der Differenzen) $V_i = \begin{cases} 1, & \text{falls } X_i - M_0 > 0 \\ 0, & \text{falls } \underbrace{X_i - M_0}_{D_i} \leq 0 \end{cases}$

Allgemeine lineare Rangstatistik

$$L_n^+ = \sum_{i=1}^n g(\Gamma(|D_i|)) \cdot V_i$$

Unterschiedliche Funktionen g führen zu unterschiedlichen Tests.

→ "Vorzeichentest": $g(x) = 1$

→ "Wilcoxon Vorzeichen-Rangtest": $g(x) = x$

Vorzeichentest (Binomialtest)

Annahmen:

Verteilungsfunktion
 $\mapsto F$

Sei X_1, \dots, X_n iid wie $X \sim F$ mit F stetig

$$H_0: \mu_{\text{med}} = M_0$$

$$H_1: \mu_{\text{med}} \neq M_0$$

Teststatistik:

$$V_n^+ = \sum_{i=1}^n V_i, \text{ wobei } V_i = \begin{cases} 1, & \text{falls } X_i - M_0 > 0 \\ 0, & \text{falls } X_i - M_0 \leq 0 \end{cases}$$

Beachte: $P_{H_0}(X_i - M_0 \leq 0) = \frac{1}{2}$

$$P_{H_0}(X_i - M_0 > 0) = 1 - P_{H_0}(X_i - M_0 \leq 0) = \frac{1}{2}$$

(folgt direkt aus der Definition des Medians)

D.h. $V_i \stackrel{H_0}{\sim} \text{Bernoulli}(p = \frac{1}{2})$

$$\Rightarrow V_n^+ \stackrel{H_0}{\sim} \text{Binomial}(n=n, p=\frac{1}{2})$$

Zweiseitiger Test:

H_0 wird abgelehnt, falls $V_{n,\text{beob}}^+$ "zu groß" ist
, d.h. falls $P_{H_0}(V_n^+ \geq V_{n,\text{beob}}^+) < \frac{\alpha}{2}$,

oder falls $V_{n,\text{beob}}^+$ "zu klein" ist,

d.h. falls $P_{H_0}(V_n^+ \leq V_{n,\text{beob}}^+) < \frac{\alpha}{2}$.

Herkunft der Verteilung (unter H_0) durch Auszähle:

Beispiel $n=5$

$$V_n^+ = V_1 + V_2 + V_3 + V_4 + V_5 \in \{0, 1, \dots, 5\}$$

$$(V_1, V_2, V_3, V_4, V_5) \in \{0, 1\}^5$$

=> 2^5 Möglichkeiten

$V_n^+=v$	$(V_1, V_2, V_3, V_4, V_5)$	$P_{H_0}(V_n^+=v)$	$P_{H_0}(V_n^+ \leq v)$
$v=0$	$(0, 0, 0, 0, 0)$	$\frac{1}{2^5} = \frac{\binom{5}{0}}{2^5}$	$\frac{\binom{5}{0}}{2^5}$
$v=1$	$(1, 0, 0, 0, 0)$ $(0, 1, 0, 0, 0)$ $(0, 0, 1, 0, 0)$ $(0, 0, 0, 1, 0)$ $(0, 0, 0, 0, 1)$	$\frac{5}{2^5} = \frac{\binom{5}{1}}{2^5}$	$\sum_{k=0}^1 \frac{\binom{5}{k}}{2^5}$

:

usw.

Allgemein

Wahrscheinlichkeitsfunktion von V_n^+ unter H_0 :

$$P_{H_0}(V_n^+ = v) = \frac{\binom{n}{v}}{2^n} \quad \text{für } v \in \{0, 1, \dots, n\}$$

Symmetrisch: $P_{H_0}(V_n^+ = v) = P_{H_0}(V_n^+ = n - v)$

denn $\binom{n}{v} = \binom{n}{n-v}$

vgl. Wahrscheinlichkeitsfunktion von $B \sim \text{Binom}(n, p)$:

$$P(B=b) = \binom{n}{b} p^b (1-p)^{n-b}$$

Verteilungsfunktionen unter H_0 :

$$P_{H_0}(V_n^+ \leq v) = \sum_{u=0}^v \frac{\binom{n}{u}}{2^n} \quad v \in \{0, \dots, n\}$$

wegen Symmetrie:

$$P_{H_0}(V_n^+ \leq v) = P_{H_0}(V_n^+ \geq n - v)$$

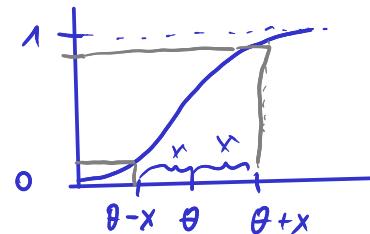
Wilcoxon's Vorzeichen-Rangtest

Annahmen:

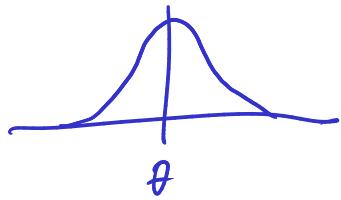
Sei X_1, \dots, X_n iid wie $X \sim F$, wobei F stetig

und symmetrisch um θ , d.h.

$$F(\theta - x) + F(\theta + x) = 1$$



$$f(\theta - x) = f(\theta + x)$$



$$H_0: M_{\text{med}} = M_0$$

$$H_1: M_{\text{med}} \neq M_0$$

Teststatistik:

$$W_n^+ = \sum_{i=1}^n r(D_i; I) V_i$$

$$V_i = \begin{cases} 1, & \text{falls } X_i - M_0 > 0 \\ 0, & \text{falls } X_i - M_0 \leq 0 \end{cases}$$

$$D_i = X_i - M_0$$

Herleitung der Verteilung von W_n^+ unter H_0

durch "Auszählen"

$$W_n^+ = \sum_{i=1}^n \underbrace{r(D_i; I)}_{\in \{0, 1\}} V_i \quad \in \left\{ 0, 1, 2, \dots, \frac{n(n+1)}{2} \right\} \quad \in \{1, \dots, n\}$$

W_n^+ ist symmetrisch verteilt mit

$$E_{H_0}(W_n^+) = \frac{n(n+1)}{4} \quad \text{und} \quad \text{Var}_{H_0}(W_n^+) = \frac{n(n+1)(2n+1)}{24}$$

Beispiel $n=5$

$$P_{H_0}(W_n^+ = \omega) = \frac{\alpha(\omega)}{2^5}$$

a(ω): Anzahl der Rangtupel mit $V_i > 0$ für welche $W_n^+ = \omega$
 von Vektoren $(r(D_1)V_1, \dots, r(D_n)V_n)$ mit $V_i > 0$

$$W_{5,\max}^+ = \sum_{i=1}^n i = \frac{n(n+1)}{2} = 15 \quad (E(W_n^+) = 7,5)$$

ω	Rangtupel mit $V_i = 1$ und $W_n^+ = \omega$	$P_{H_0}(W_n^+ = \omega) = \frac{a(\omega)}{2^n}$	wegen Symmetrie
15	(1, 2, 3, 4, 5)	$\frac{1}{32}$	$\omega = 0$ (0, 0, 0, 0, 0)
14	(2, 3, 4, 5)	$\frac{1}{32}$	$\omega = 1$ (1, 0, 0, 0, 0)
13	(1, 3, 4, 5)	$\frac{1}{32}$	$\omega = 2$ (0, 1, 0, 0, 0)
12	(3, 4, 5) (1, 2, 4, 5)	$\frac{2}{32}$	$\omega = 3$ (1, 1, 0, 0, 0) (0, 0, 1, 0, 0)
11	(1, 2, 3, 5) (2, 4, 5)	$\frac{2}{32}$	$\hat{\omega} = 4$
10	(1, 2, 3, 4) (2, 3, 5) (1, 4, 5)	$\frac{3}{32}$	$\hat{\omega} = 5$
9	(4, 5); (2, 3, 4); (1, 3, 5)	$\frac{3}{32}$	$\hat{\omega} = 6$
8	(3, 5); (1, 3, 4); (1, 2, 5)	$\frac{3}{32}$	$\hat{\omega} = 7$

Zweistichprobenprobleme:

Lineare Rangtests

Allgem. lineare Rangstatistik

$$L_N = \sum_{i=1}^N a_i V_i$$

$$V_i = \begin{cases} 1, & \text{falls } i\text{-te Ordnungsstatistik eine X-Variable ist} \\ 0, & \text{sonst} \end{cases}$$

$$\mathbb{E}(V_i) = 1 \cdot \frac{m}{N} + 0 \cdot \frac{n}{N} = \frac{m}{N}$$

$$\text{Var}(V_i) = \mathbb{E}(V_i^2) - (\mathbb{E}(V_i))^2$$

$$= \underbrace{1^2 \frac{m}{N} + 0^2 \frac{n}{N}} - \left(\frac{m}{N}\right)^2 = \frac{m(m+n)}{N^2} - \frac{m^2}{N^2} = \frac{mn}{N^2}$$

$$\text{Cov}(V_i, V_j) = \underline{\mathbb{E}(V_i V_j)} - \mathbb{E}(V_i) \mathbb{E}(V_j)$$

($i \neq j$)

$$\underline{\mathbb{E}(V_i V_j)} = 1 \cdot P(V_i=1, V_j=1) + 0$$

$$= 1 \cdot P(V_i=1 \mid V_j=1) \cdot P(V_j=1)$$

$$= 1 \cdot \frac{m-1}{N-1} \cdot \frac{m}{N}$$

$$\Rightarrow \text{Cov}(V_i, V_j) = \frac{(m-1)m}{(N-1)N} - \left(\frac{m}{N}\right)^2 = \dots = \frac{-nm}{N^2(N-1)}$$

$$E(L_N) = \sum_{i=1}^N a_i E(V_i) = \frac{m}{N} \sum_{i=1}^N a_i$$

$$\text{Var}(L_N) = \text{Var}\left(\sum_{i=1}^N a_i V_i\right)$$

$$= \sum_{i=1}^N a_i^2 \text{Var}(V_i) + \sum_{i=1}^N \sum_{\substack{j=1 \\ (i \neq j)}}^N a_i a_j \text{Cov}(V_i, V_j)$$

$$= \frac{mn}{N^2} \sum_{i=1}^N a_i^2 - \frac{nm}{N^2(N-1)} \sum_{i=1}^N \sum_{\substack{j=1 \\ (i \neq j)}}^N a_i a_j$$

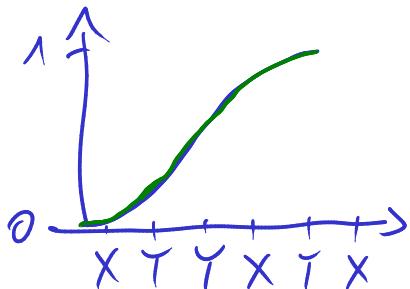
$$= \frac{mn}{N^2(N-1)} \left[(N-1) \sum_{i=1}^N a_i^2 - \sum_{i=1}^N \sum_{\substack{j=1 \\ (i \neq j)}}^N a_i a_j \right]$$

$$= \frac{mn}{N^2(N-1)} \left[N \sum_{i=1}^N a_i^2 - \underbrace{\sum_{i=1}^N \sum_{j=1}^N a_i a_j}_{= \left(\sum_{i=1}^N a_i \right)^2} \right]$$

$$= \frac{mn}{N^2(N-1)} \left[N \sum_{i=1}^N a_i^2 - \left(\sum_{i=1}^N a_i \right)^2 \right]$$

Lagealternativen

$$H_0: F_X = F_Y$$

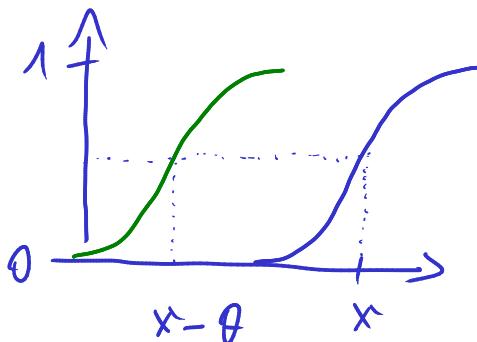


$$V_i: 1 \underline{0} 0 1 0 1$$

$$a_i: \underline{1} 2 3 \underline{4} 5 \underline{6}$$

$$W_N = \sum_{i=1}^N a_i V_i = 11$$

$$H_1: F_X(x) = F_Y(x - \theta), \text{ für alle } x \in \mathbb{R}, \theta \neq 0$$



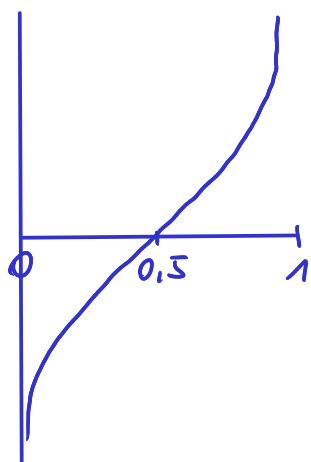
$$V_i: 0 \underline{0} 0 1 1 1$$

$$a_i: \underline{1} 2 3 \underline{4} \underline{5} \underline{6}$$

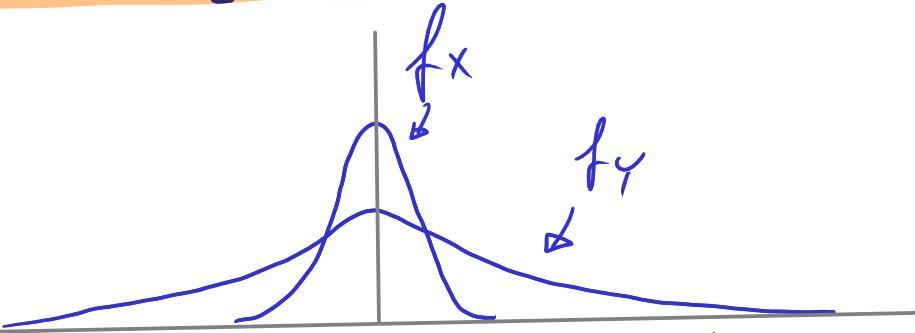
$$W_N = \sum_{i=1}^N a_i V_i = 15$$

a_i beim Test von v.d. Waerden

$$a_i = \Phi^{-1}\left(\frac{i}{N+1}\right) \quad ; \quad i = 1, \dots, N$$



Siegel - Tukey Test



V:	Y Y T Y	X X T X Y X	Y Y Y
	0 0 0 0	1 1 0 1 0 1	0 0 0
a:	1 4 5 8	g 12 13 11 10 7	6 3 2
	= =	= =	= =

$$S_N = g + 12 + 11 + 7$$

K-S Test im Zweistichprobensproblem

BSP: $m=2$ und $n=3$ ($N=m+n=5$)

$$\Rightarrow \text{Es gibt } \binom{n+m}{n} = \binom{5}{3} = 10 \quad \text{z.B. } (X Y X T Y)$$

verschiedene Realisationsmöglichkeiten der kombinierten geordneten Stichprobe.

$$P_{H_0}(\mathbb{D}_{m,n}=1) = \frac{2}{10} \left\{ \begin{array}{l} (X, X, Y, Y, T) \\ (Y, Y, T, X, X) \end{array} \right\} \mathbb{D}_{m,n}=1$$

$$P_{H_0}(\mathbb{D}_{m,n} = \frac{2}{3}) = \frac{4}{10} \left\{ \begin{array}{l} (Y, X, X, Y, Y) \\ (Y, Y, X, X, Y) \\ (Y, Y, X, Y, X) \\ (X, Y, X, Y, Y) \end{array} \right\} \mathbb{D}_{m,n} = \frac{2}{3}$$

$$P_{H_0}(\mathbb{D}_{m,n} = \frac{1}{2}) = \frac{3}{10} \left\{ \begin{array}{l} (X, Y, Y, X, Y) \\ (X, Y, Y, Y, X) \\ (Y, X, Y, Y, X) \end{array} \right\} \mathbb{D}_{m,n} = \frac{1}{2}$$

$$P_{H_0}(\mathbb{D}_{min} = \frac{1}{3}) = \frac{1}{10} \left\{ (Y, X, Y, X, Y) \right\} \mathbb{D}_{min} = \frac{1}{3}$$

Übungsbatt #2

Aufg 2 $P(r(X_i) = b, r(X_j) = l) \quad i \neq j$

Einzelne Schritte:

- $P(r(X_i) = b, r(X_j) = l) =$
 $= \underbrace{P(r(X_i) = b | r(X_j) = l)}_{\frac{1}{n-1}} \cdot \underbrace{P(r(X_j) = l)}_{\frac{1}{n}} = \frac{1}{n(n-1)}$

- $\sum_{k=1}^n \sum_{l=1}^n kl = ?$

$k \neq l$

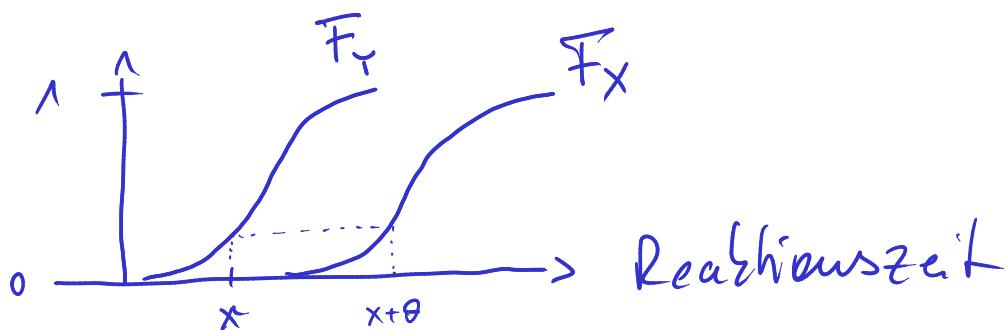
$$\begin{bmatrix} \cancel{11} & 12 & \cdots & 1n \\ 21 & \cancel{22} & \cdots & 2n \\ \vdots & & \ddots & \cancel{n n} \end{bmatrix} \rightarrow \begin{array}{l} 1 \cdot \frac{n(n+1)}{2} - 1 \cdot 1 \\ 2 \cdot \frac{n(n+1)}{2} - 2 \cdot 2 \\ \vdots \quad \quad \quad n \cdot \frac{n(n+1)}{2} - n \cdot n \end{array}$$

für die kte Zeile: $b \cdot \frac{n(n+1)}{2} - b^2$

Summe über alle Zeilen: $\sum_{k=1}^n \left(b \cdot \frac{n(n+1)}{2} - b^2 \right) =$

$$= \frac{n(n+1)}{2} \sum_{k=1}^n k - \sum_{k=1}^n k^2$$

Aufg 3



a) $H_0 : F_Y = F_X \quad H_1 : F_Y(x) = F_X(x+\theta)$

$H_0 : F_Y(x) = F_X(x+\theta)$ für $\theta \leq 0$

b) Notiz: $E(W_N) = E\left(\sum_{i=1}^m r(X_i)\right)$

$$= \sum_{i=1}^m E(r(X_i))$$

$$= \sum_{i=1}^m \left(\sum_{k=1}^N \frac{1}{N} k \right)$$

$$= m \left(\frac{1}{N} \sum_{k=1}^N k \right)$$

$$= m \cdot \frac{1}{N} \frac{N(N+1)}{2} = \frac{m(N+1)}{2}$$

Kap 3.

$$\hat{\theta}_n = g(X_1, \dots, X_n)$$

Erwartungstreue von $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

$$\mathbb{E}(\bar{X}_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i)$$

Da X_1, \dots, X_n alle iid wie $X \sim F_X$

mit $\mathbb{E}(X) = \mu$

$$= \frac{1}{n} \sum_{i=1}^n \mu = \frac{n}{n} \mu = \mu$$

Folie 18

$$MSE(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2] =$$

$$= \mathbb{E}\left[\underbrace{(\hat{\theta}_n - \mathbb{E}(\hat{\theta}_n))}_{=0} + (\mathbb{E}(\hat{\theta}_n) - \theta)^2\right]$$

$$= \mathbb{E}\left[(\hat{\theta}_n - \mathbb{E}(\hat{\theta}_n))^2 + 2(\hat{\theta}_n - \mathbb{E}(\hat{\theta}_n))(\mathbb{E}(\hat{\theta}_n) - \theta) + (\mathbb{E}(\hat{\theta}_n) - \theta)^2\right]$$

$$\text{Bias}(\hat{\theta}_n) = \mathbb{E}(\hat{\theta}_n) - \theta$$

$$= \underbrace{\mathbb{E}[(\hat{\theta}_n - \mathbb{E}(\hat{\theta}_n))^2]}_{\text{Var}(\hat{\theta}_n)} + 2(\mathbb{E}(\hat{\theta}_n) - \theta) \underbrace{\mathbb{E}[\hat{\theta}_n - \mathbb{E}(\hat{\theta}_n)]}_{\mathbb{E}(\hat{\theta}_n) - \mathbb{E}(\hat{\theta}_n)} + (\text{Bias}(\hat{\theta}_n))^2$$

$$= \text{Var}(\hat{\theta}_n) + (\text{Bias}(\hat{\theta}_n))^2$$

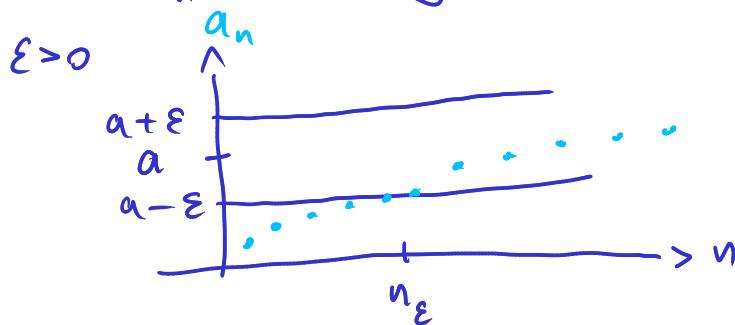
Konsistenz

Ausflug zu deterministischen Folgen

$$a_n \rightarrow a \text{ für } n \rightarrow \infty$$

" a_n konvergiert zu a^n "

D.h. Für hinreichend große n , ist und bleibt a_n beliebig nahe bei a .



Für jedes $\varepsilon > 0$
gibt es ein n_ε , sodass
 $|a_n - a| \leq \varepsilon$ für alle $n \geq n_\varepsilon$
 $\Leftrightarrow a_n \rightarrow a$, für $n \rightarrow \infty$

$\Delta \hat{\theta}_n$ ist jedoch eine Zufallsvariable!

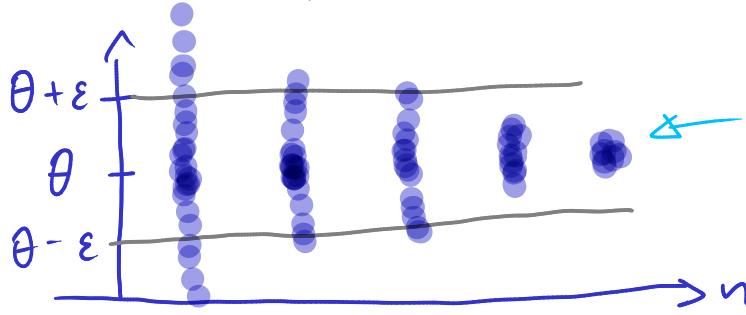
Z>(Eine) Lösung: "Konvergenz in Wahrscheinlichkeit"

Konvergenz in Wahrscheinlichkeit

$$\hat{\theta}_n \xrightarrow{P} \theta, n \rightarrow \infty$$

\Leftrightarrow D.h. für jedes $\varepsilon > 0$

$$P(|\hat{\theta}_n - \theta| < \varepsilon) \rightarrow 1 \text{ für } n \rightarrow \infty$$



Realisationen von $\hat{\theta}_n$
für verschiedene n .

Behauptung $\hat{\theta}_n \xrightarrow{\text{MSE}} \theta \Rightarrow \hat{\theta}_n \xrightarrow{P} \theta$

D.h. $\lim_{n \rightarrow \infty} \mathbb{E}[(\hat{\theta}_n - \theta)^2] = 0 \Rightarrow \lim_{n \rightarrow \infty} P[|\hat{\theta}_n - \theta| < \varepsilon] = 1$

Beweis:

Tool: Markov-Ungleichung

$$P(X \geq c) \leq \frac{\mathbb{E}(X)}{c} \quad \begin{matrix} \text{Zufallsvariable} \\ \downarrow \\ \text{mit } X \geq 0 \\ \text{und } 0 < c < \infty \\ \text{Konstante} \end{matrix}$$

$$P[\underbrace{(\hat{\theta}_n - \theta)^2}_{=X} \geq \varepsilon^2] \leq \frac{\mathbb{E}[(\hat{\theta}_n - \theta)^2]}{\varepsilon^2}$$

$$\Leftrightarrow |\hat{\theta}_n - \theta| \geq \varepsilon \quad \mathbb{E}[(\hat{\theta}_n - \theta)^2] \} = \text{MSE}(\hat{\theta}_n)$$

$$\Leftrightarrow P[|\hat{\theta}_n - \theta| \geq \varepsilon] \leq \frac{\mathbb{E}[(\hat{\theta}_n - \theta)^2]}{\varepsilon^2}$$

Dies zeigt die Behauptung, denn:

$$1.) \lim_{n \rightarrow \infty} \frac{\mathbb{E}[(\hat{\theta}_n - \theta)^2]}{\varepsilon^2} = 0$$

$$2.) 0 \leq P[|\hat{\theta}_n - \theta| \geq \varepsilon]$$

□

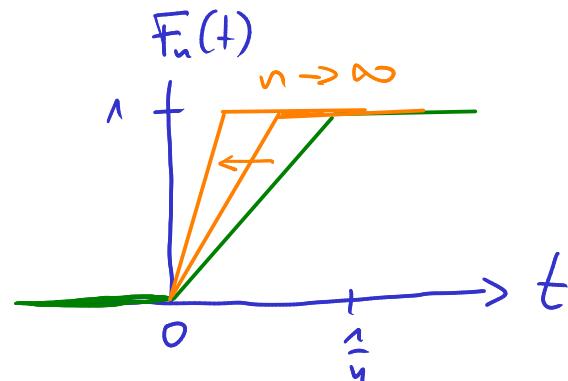
Konvergenz in Verteilung

Def $\lim_{n \rightarrow \infty} F_n(t) = F(t)$, für alle Stetigkeitspunkte t , von F .

Bsp:

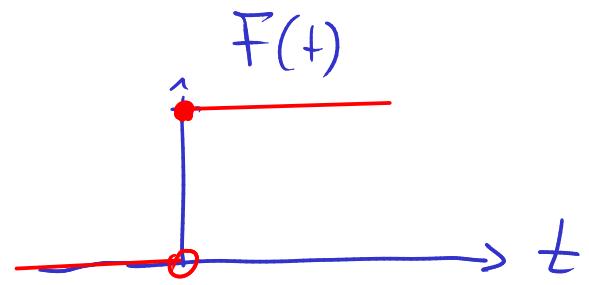
$$Z_n \sim U[0, \frac{1}{n}]$$

$$F_n(t) = \begin{cases} 0, & t < 0 \\ t^n, & 0 \leq t \leq \frac{1}{n} \\ 1, & t > \frac{1}{n} \end{cases}$$



$$Z_\infty = 0$$

$$(F_\infty(t) =) F(t) = \begin{cases} 0, & t < 0 \\ 1, & t \geq 0 \end{cases}$$



D.h. für alle $t > 0$ existiert ein m_t , sodass $F_n(t) = F(t) = 1$, für alle $n \geq m_t$.

Ljapunow

$$\frac{\frac{1}{n} \sum_{i=1}^n (X_i - M_i)}{\sqrt{\frac{1}{n} \left(\sum_{i=1}^n S_i^2 \right)^{1/2}}} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - M_i)}{\sqrt{\frac{1}{n} \left(\sum_{i=1}^n S_i^2 \right)^{1/2}}} =$$

$$= \frac{\frac{1}{n} \sum_{i=1}^n (X_i - M_i)}{\sqrt{\frac{1}{n} \left(\frac{1}{n} \sum_{i=1}^n S_i^2 \right)^{1/2}}} = \frac{\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n (X_i - M_i) \right)}{\left(\frac{1}{n} \sum_{i=1}^n S_i^2 \right)^{1/2}}$$

ZGS von

Lindeberg-Lévy: $E(X_i) = M$ für alle $i = 1, \dots, n$
 $\text{Var}(X_i) = S^2$ für alle $i = 1, \dots, n$

$$\frac{\sqrt{n} (\bar{X}_n - M)}{S} \xrightarrow{D} N(0, 1), \text{ für } n \rightarrow \infty$$

Tschebyeschoff

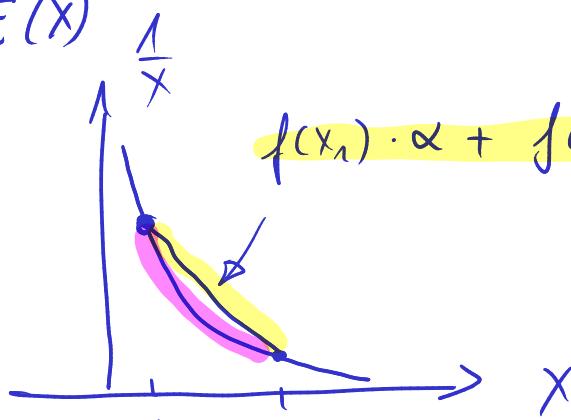
$$P(|X - M| > k \cdot S_x) \leq \frac{1}{k^2} \left(= \left(\frac{1}{k} \right)^2 \right), k > 0$$

$$\text{mit } k = \frac{\tilde{k}}{S_x} \Leftrightarrow \tilde{k} = k \cdot S_x, \quad \tilde{k} > 0$$

$$P(|X - M| > \tilde{k}) \leq \frac{S_x^2}{\tilde{k}^2} \quad \text{mit } S_x^2 = \text{Var}(X)$$

Jensens Ungleichung

$$\mathbb{E}\left(\frac{1}{X}\right) \geq \frac{1}{\mathbb{E}(X)}$$



$$f(x_1 \alpha + x_2 (1-\alpha)) \leq f(x_1) \alpha + f(x_2) (1-\alpha)$$

Deterministische Ordnungssymbole

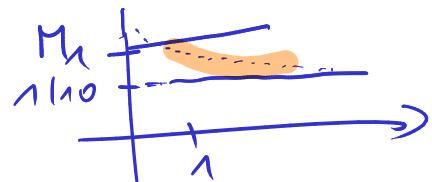
$$z_n = O(1)$$

" $|z_n|$ ist beschränkt für alle hinreichend großen n ".

\Leftrightarrow "Es existiert M_m , sodass $|z_n| \leq M_m$ für alle $n \geq m$ ".

BSP

$$z_n = \frac{1}{n} + \frac{1}{10}$$



$$\Rightarrow |z_n| \leq M_1 = 1,1 \text{ für alle } n \geq 1$$

$$\Rightarrow z_n = O(1)$$

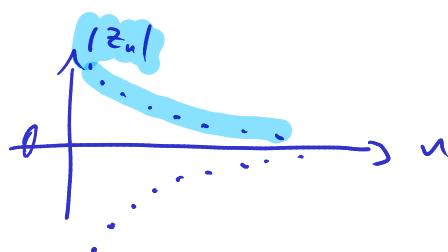
$$z_n = o(1)$$

" $|z_n|$ ist eine "Nullfolge" (d.h. $|z_n| \xrightarrow{n \rightarrow \infty} 0$)."

BSP

a) $z_n = -\frac{1}{n}$

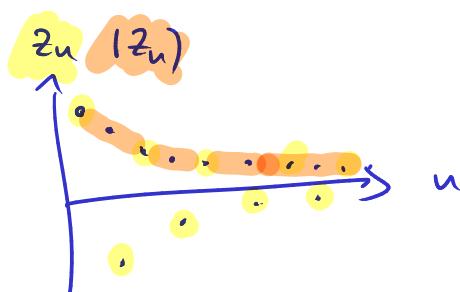
$$\Rightarrow |z_n| \rightarrow 0 \text{ für } n \rightarrow \infty$$



$$\Leftrightarrow z_n = o(1)$$

b) $z_n = \frac{1}{n} (-1)^n$

$$|z_n| \rightarrow 0, n \rightarrow \infty$$



$$\Leftrightarrow z_n = o(1)$$

Beachte:

$$z_n = o(1) \Rightarrow z_n = O(1)$$

$$z_n = O(\Gamma_n) \Leftrightarrow \frac{z_n}{\Gamma_n} = O(1)$$

\Leftrightarrow " $|z_n|$ ist von gleicher oder kleinerer Größenordnung wie/als $|\Gamma_n|$ ".

\Leftrightarrow " $\frac{|z_n|}{|\Gamma_n|}$ ist beschränkt für hinreichend große n "

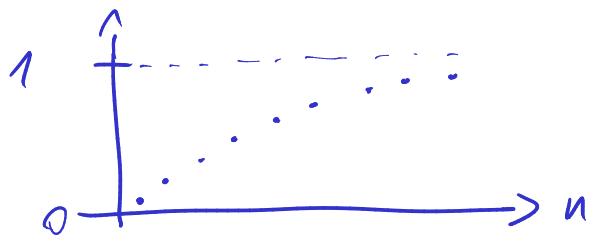
$$\left(\exists M_m > 0, \text{ sodass } 0 \leq \frac{|z_n|}{|\Gamma_n|} \leq M_m \text{ für alle } n \geq m \right)$$

BSP:

$$z_n = \frac{1}{100+n^2}$$

$$\Gamma_n = n^{-2}$$

$$\frac{|z_n|}{|\Gamma_n|} = \frac{n^2}{100+n^2}$$



$$\Rightarrow 0 \leq \frac{|z_n|}{|\Gamma_n|} \leq M = 1 \quad \text{für alle } n \geq 1$$

$$\Leftrightarrow \frac{z_n}{\Gamma_n} = O(1)$$

$$\Leftrightarrow z_n = O(\Gamma_n)$$

$$z_n = o(\Gamma_n) \Leftrightarrow \frac{z_n}{\Gamma_n} = o(1)$$

\Leftrightarrow " $|z_n|$ ist von kleinerer Größenordnung als $|\Gamma_n|$. "

\Leftrightarrow " $\frac{|z_n|}{|\Gamma_n|}$ ist eine Nullfolge. "

BSP $z_n = \frac{1}{n^2} \quad \Gamma_n = \frac{1}{n}$

$$\frac{|z_n|}{|\Gamma_n|} = \frac{n}{n^2} = \frac{1}{n} \xrightarrow{n \rightarrow \infty} 0$$

$$\Rightarrow z_n = o(\Gamma_n)$$

BSP $z_n = \sum_{i=1}^n i = O(n^2)$

$$z_n = \sum_{i=1}^n i = \frac{n(n+1)}{2} = \frac{n^2+n}{2}$$

$$\Gamma_n = n^2$$

$$\frac{|z_n|}{|\Gamma_n|} = \frac{\frac{n^2+n}{2}}{n^2} = \dots = \frac{1}{2} + \frac{1}{2n}$$

$$\Rightarrow \frac{|z_n|}{|\Gamma_n|} \leq M = 1 \text{ for all } n \geq 1$$

$$\Rightarrow \frac{n^2+n}{2} = O(n^2)$$

BSP $z_n = \sum_{i=1}^n i = o(n^3)$

$$z_n = \frac{n^2+n}{2}$$

$$\Gamma_n = n^3$$

$$\frac{|z_n|}{|\Gamma_n|} = \frac{1}{2} n^{-1} + \frac{1}{2} n^{-2} \xrightarrow[n \rightarrow \infty]{} 0$$

$$\Rightarrow \frac{z_n}{\Gamma_n} = o(1) \Leftrightarrow z_n = o(\Gamma_n)$$

$$Z_n = O_p(1)$$

\Leftrightarrow " $|Z_n|$ ist stochastisch beschränkt für alle hinreichend großen n ."

BSP $Z_n \sim N(0,1)$ für alle n

$$\Rightarrow P(|Z_n| > z_{1-\frac{\varepsilon}{2}}) = \varepsilon \quad \text{für alle } n \geq 1$$

$$\Leftrightarrow Z_n = O_p(1)$$

$$Z_n = o_p(1)$$

$$\Leftrightarrow Z_n \xrightarrow{P} 0 \quad \text{für } n \rightarrow \infty$$

BSP $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ mit $X_i \sim N(\mu, \sigma^2)$, für alle:

$$Z_n = \bar{X}_n - \mu \xrightarrow[n \rightarrow \infty]{P} 0$$

$$\Leftrightarrow Z_n = \bar{X}_n - \mu = o_p(1)$$

$$(\bar{X}_n - \mu) = O_p(n^{-1/2})$$

$$\Leftrightarrow \sqrt{n}(\bar{X}_n - \mu) = O_p(1)$$

Laut dem zentralen Grenzwertsatz (angenommen alle Voraussetzungen sind erfüllt)

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{n \rightarrow \infty} Z \sim N(0, \sigma^2)$$

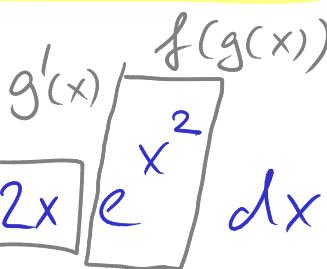
$$\Rightarrow \sqrt{n}(\bar{X}_n - \mu) = O_p(1)$$

$$\Leftrightarrow (\bar{X}_n - \mu) = O_p(n^{-1/2})$$

Integration durch Substitution

Bsp

$$\int_0^2 x e^{x^2} dx = \frac{1}{2} \int_0^2 [2x] e^{x^2} dx =$$



Substitution

$$u = x^2 \Rightarrow \frac{du}{dx} = 2x \quad (\Rightarrow \frac{1}{2x} du = dx)$$

$$u(2) = 2^2 = 4$$

$$u(0) = 0^2 = 0$$

$$= \frac{1}{2} \int_0^4 [2x] e^u \frac{1}{2x} du = \frac{1}{2} \int_0^4 e^u du = \frac{1}{2} [e^u]_0^4 = \frac{1}{2}(e^4 - 1)$$

Partielle Integration

BSP

$$\int_1^2 x^2 \ln(x) dx = \left[\frac{1}{3} x^3 \cdot \ln(x) \right]_1^2 - \int_1^2 \frac{1}{3} x^3 \cdot \frac{1}{x} dx =$$

$$= \left(\frac{8}{3} \ln(2) - 0 \right) - \frac{1}{3} \int_1^2 x^2 dx$$

$$= \left(\frac{8}{3} \ln(2) \right) - \frac{1}{3} \left[\frac{1}{3} x^3 \right]_1^2 = \frac{8}{3} \ln(2) - \left(\frac{8}{9} - \frac{1}{9} \right)$$

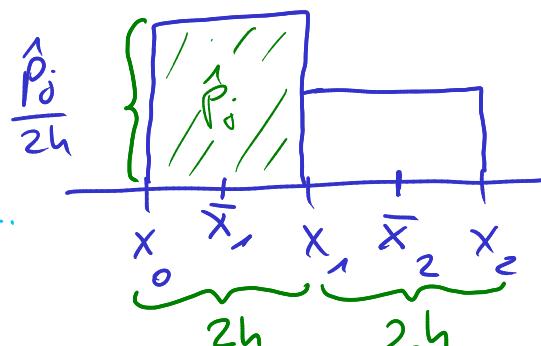
Kap4 Nichtparametrische Dichteschätzung

Ann: $X_1, \dots, X_n \stackrel{iid}{\sim} X$ mit $X = F$ (bzw. $X \sim f = F'$)

Frage: $f = ?$

Das Histogramm

$\bar{x}_j = \frac{x_{j-1} + x_j}{2}$, wobei $(x_j)_{j=0,1,2,\dots}$
 ↓ die Balkenränder definiert.



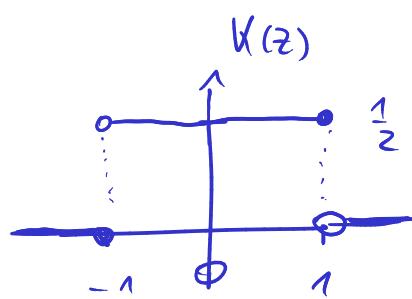
$$\hat{f}_{\text{hist}}(\bar{x}_j) = \frac{\#\{X_i \in (x_{j-1}, x_j]\}}{2hn}$$

$$= \frac{1}{2h} \cdot \hat{P}_j, \text{ wobei } \hat{P}_j = \frac{\#\{X_i \in (x_{j-1}, x_j]\}}{n}$$

$$\hat{f}_{\text{hist}}(\bar{x}_j) = \frac{1}{2h} \cdot \frac{1}{n} \sum_{i=1}^n \mathbb{I}(x_{j-1} < X_i \leq x_j)$$

$$= \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} \mathbb{I}(x_{j-1} < X_i \leq x_j)$$

$$= \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - \bar{x}_j}{h}\right)$$



für $K(z) = \begin{cases} \frac{1}{2} & \text{für } z \in (-1, 1] \\ 0 & \text{sonst} \end{cases}$

Da $K(z)$ achsensymmetrisch: $K\left(\frac{X_i - \bar{x}_j}{h}\right) = K\left(\frac{\bar{x}_j - X_i}{h}\right)$

Wie gut ist $\frac{F(x+h) - F(x)}{h} \approx F'(x)$?

Behauptung $F'(x) = \frac{F(x+h) - F(x)}{h} + O(h)$ für $h \rightarrow 0$

Bew:

Taylorentwicklung von F um x für $h \rightarrow 0$:

$$F(x+h) = F(x) + F'(x)h + \frac{1}{2} F''(x)h^2 + o(h^2)$$

$$\Rightarrow \frac{F(x+h) - F(x)}{h} = \frac{F'(x)h + \frac{1}{2} F''(x)h^2 + o(h^2)}{h}$$

$$\begin{cases} v_n = O(h^{-1}) \quad \text{und} \quad z_n = o(h^2) \\ \Rightarrow v_n z_n = o(h) \end{cases}$$

$$\Rightarrow \frac{F(x+h) - F(x)}{h} = F'(x) + \underbrace{\frac{1}{2} F''(x)h}_{O(h)} + o(h)$$

$$\Rightarrow \frac{F(x+h) - F(x)}{h} = \underbrace{F'(x)}_{f(x)} + O(h)$$

Bias des Kondichteschätzors

$$\hat{f}_{nh}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right), \quad x \in \mathbb{R}$$

Ann: • $X_1, \dots, X_n \stackrel{iid}{\sim} X$ mit $X \sim f$

- f sei zweimal stetig differenzierbar
- $n \rightarrow \infty, h = h_n \rightarrow 0, nh_n \rightarrow \infty$
- K wie auf Folie 35

Satz: Unter obigen Annahmen lautet der Bias von $\hat{f}_{nh}(x)$:

$$\begin{aligned} \text{Bias}(\hat{f}_{nh}(x)) &= \mathbb{E}(\hat{f}_{nh}(x)) - f(x) \\ &= \frac{1}{2} f''(x) v_2(K) h^2 + o(h^2), \end{aligned}$$

$$\text{wobei } v_2(K) = \int K(y) y^2 dy$$

Beweis:

$$\begin{aligned} \mathbb{E}[\hat{f}_{nh}(x)] &= \frac{1}{nh} \sum_{i=1}^n \mathbb{E}\left[K\left(\frac{x-X_i}{h}\right)\right] \quad \text{iid} \\ &= \frac{1}{h} \mathbb{E}\left[K\left(\frac{x-X}{h}\right)\right] \\ &= \frac{1}{h} \mathbb{E}\left[K\left(\frac{X-x}{h}\right)\right] \quad | K \text{ symmetrisch} \\ &= \frac{1}{h} \int K\left(\frac{z-x}{h}\right) f(z) dz \end{aligned}$$

$$\text{Subst } \frac{z-x}{h} = y \Rightarrow \frac{dz}{dy} = \frac{1}{h} \Leftrightarrow dz = h dy$$

$$\Leftrightarrow z = x + hy$$

$$= \frac{h}{h} \int K(y) f(x+hy) dy$$

$$f(x+hy) = f(x) + f'(x)hy + \frac{1}{2}f''(x)h^2y^2 + o(h^2)$$

$$= \int K(y) [f(x) + f'(x)hy + \frac{1}{2}f''(x)h^2y^2 + o(h^2)] dy$$

$$= f(x) \underbrace{\int K(y) dy}_{=1} + f'(x) h \underbrace{\int K(y) y dy}_{=0} + \frac{1}{2} f''(x) h^2 \underbrace{\int K(y) y^2 dy}_{=V_2(K)} + o(h^2)$$

$$\Rightarrow \mathbb{E}(\hat{f}_{nh}(x)) = f(x) + \frac{1}{2} f''(x) V_2(K) h^2 + o(h^2)$$

□

Asymptotischer Bias:

$$ABias(\hat{f}_{nh}(x)) = \frac{1}{2} f''(x) V_2(K) h^2$$

denn:

$$\frac{Bias(\hat{f}_{nh}(x))}{ABias(\hat{f}_{nh}(x))} = 1 + o(h^2)$$

Satz: Unter obiger Annahme lautet die Varianz von $\hat{f}_{nh}(x)$:

$$Var(\hat{f}_{nh}(x)) = \frac{1}{n} \frac{f(x) R(K)}{h} + O\left(\frac{1}{n}\right),$$

$$\text{wobei } R(K) = \int (K(y))^2 dy$$

Beweis:

$$\text{Var}\left(\hat{f}_{nh}(x)\right) = \frac{1}{n^2 h^2} \sum_{i=1}^n \text{Var}\left[K\left(\frac{x-x_i}{h}\right)\right]$$

iid

$$= \frac{1}{n h^2} \text{Var}\left[K\left(\frac{x-X}{h}\right)\right]$$

$$= \frac{1}{nh^2} \mathbb{E}\left[\left(K\left(\frac{x-X}{h}\right)\right)^2\right] - \frac{1}{n} \left\{ \underbrace{\frac{1}{h} \mathbb{E}\left[K\left(\frac{x-X}{h}\right)\right]} \right\}^2$$

$\mathbb{E}\left[\hat{f}_{nh}(x)\right]$ siehe \star

$$= \underbrace{\frac{1}{nh^2} \mathbb{E}\left[\left(K\left(\frac{x-X}{h}\right)\right)^2\right]}_{\text{NR}} - \underbrace{\frac{1}{n} \left\{ \mathbb{E}\left(\hat{f}_{nh}(x)\right) \right\}^2}_{0 \leq \text{const} < \infty}$$

$$\frac{1}{n} \text{const} = O(n^{-1})$$

NR:

K symmetrisch

$$\frac{1}{nh^2} \mathbb{E}\left[\left(K\left(\frac{x-X}{h}\right)\right)^2\right] = \frac{1}{nh^2} \mathbb{E}\left[\left(K\left(\frac{X-x}{h}\right)\right)^2\right] =$$

$$= \frac{1}{nh^2} \int \left(K\left(\frac{z-x}{h}\right)\right)^2 f(z) dz = \frac{1}{nh^2} \int \underbrace{\left(K(y)\right)^2}_{f(x) + O(h)} \underbrace{\int (x+hy) dy}_{dy} dy$$

Taylorsapprox 1. Ordnung

$$= \frac{1}{nh} f(x) \underbrace{\int (u(y))^2 dy}_{R(K)} + \underbrace{\frac{1}{nh} R(K) O(h)}_{= O(\frac{1}{n})}$$

Damit:

$$\begin{aligned} \text{Var}(\hat{f}_{nh}(x)) &= \frac{1}{nh} f(x) R(K) + O(\frac{1}{n}) + O(\frac{1}{n^2}) \\ &= \frac{1}{nh} f(x) R(K) + \underbrace{O(\frac{1}{n})}_{= o\left(\frac{1}{nh}\right)} \end{aligned}$$

Asymptotische Varianz

$$\text{AVar}(\hat{f}_{nh}(x)) = \frac{R(K) f(x)}{nh}$$

denn:

$$\frac{\text{Var}(\hat{f}_{nh}(x))}{\text{AVar}(\hat{f}_{nh}(x))} = 1 + o\left(\frac{1}{nh}\right)$$

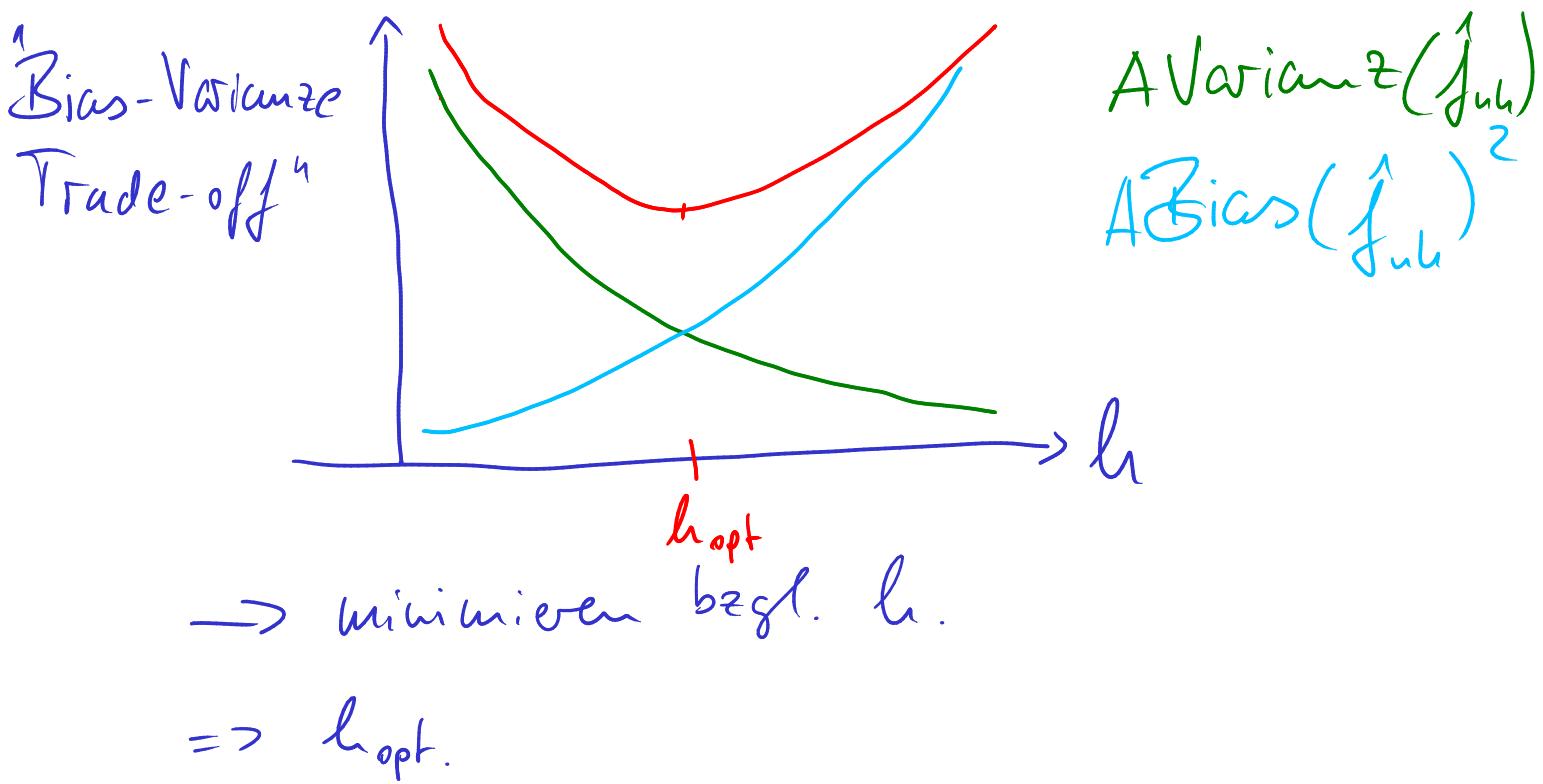
Asymptotischen mittleren quadratischen Fehler von

$\hat{f}_{nh}(x)$:

$$\text{AMSE}(\hat{f}_{nh}(x)) = \frac{f(x) R(K)}{nh} + \left(\frac{1}{2} f''(x) J_2(K) h^2 \right)^2$$

$$\text{AMISE}(\hat{f}_{nh}) = \int \text{AMSE}(\hat{f}_{nh}(x)) dx$$

$$AMISE(\hat{f}_{nh}) = \frac{R(h)}{nh} + \frac{1}{4} (\lambda_2(h))^2 h^4 \int (f''(x))^2 dx$$



Kreuzvalidierung (Ziel: h_{ISE})

Behauptung:

$$\frac{1}{n} \sum_{i=1}^n \hat{f}_{nh,-i}(X_i)$$

ist ein "vernünftiger" Schätzer für $\int \hat{f}_{nh}(x) f(x) dx$,

zumindest in dem Sinne, dass

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \hat{f}_{nh,-i}(X_i)\right] = \mathbb{E}\left[\int \hat{f}_{nh}(x) f(x) dx\right]$$

Beweis zu dieser Behauptung

$$NR: \frac{1}{n} \sum_{i=1}^n \hat{f}_{nh,-i}(X_i) =$$

$$= \frac{1}{n} \sum_{i=1}^n \left[\frac{1}{(n-1)h} \sum_{\substack{j=1 \\ (j \neq i)}}^n K\left(\frac{X_j - X_i}{h}\right) \right]$$

$$= \frac{1}{n(n-1)h} \sum_{i=1}^n \sum_{\substack{j=1 \\ (j \neq i)}}^n K\left(\frac{X_j - X_i}{h}\right)$$

$X_1, \dots, X_n \stackrel{iid}{\sim} X$

$X_j \perp\!\!\!\perp X_i$

"unabhängig von"

$$E \left[\frac{1}{n} \sum_{i=1}^n \hat{f}_{nh,-i}(X_i) \right] =$$

wegen iid

$$= E \left[\frac{1}{n} K\left(\frac{X_i - X_j}{h}\right) \right] =$$

mit $i \neq j$

$$= \iint \frac{1}{n} K\left(\frac{x - u}{h}\right) f(x) f(u) dx du$$

wegen Unabhängigkeit zwischen X_i und X_j

$$E \left[\int \frac{1}{h} K\left(\frac{x - X_i}{h}\right) f(x) dx \right] =$$

$$\begin{aligned}
 &= E \left[\int \frac{1}{h^n} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right) f(x) dx \right] = \text{wegen iid} \\
 &= E \left[\int \hat{f}_{nh}(x) f(x) dx \right]
 \end{aligned}$$

□

Übungsbuch 3

